ANÁLISE DE DADOS: COVID 2020

TECH CHALLENGE FASE 3

DEBORA RIBEIRO DE SOUZA | RM 368669
GUILHERME PAULO FERREIRA | RM 367422
JAQUELINE DE SOUZA OLIVEIRA | RM 367545

ANÁLISE DO COMPORTAMENTO DA POPULAÇÃO BRASILEIRA DURANTE A PANDEMIA UTILIZANDO DADOS DA PNAD COVID-19.

Este projeto tem como objetivo analisar dados da pesquisa PNAD COVID-19, disponibilizada pelo IBGE, a fim de compreender o comportamento da população durante o período da pandemia.

A partir da seleção de variáveis relevantes relacionadas a sintomas clínicos, características da população e aspectos econômicos, foi estruturada uma base de dados em ambiente de nuvem para apoiar análises exploratórias e geração de indicadores.

ARQUITETURA DO AMBIENTE

Ingestão via VSCODE do CSV

Amazon S3

Amazon Glue

Amazon Athena

Power BI

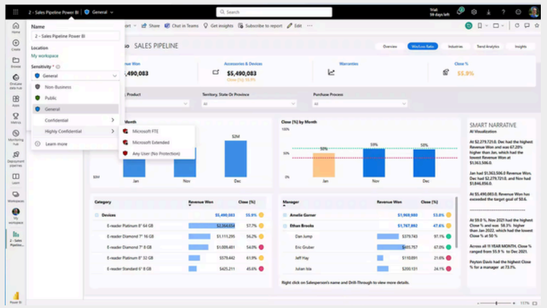

BRONZE: Armazena os dados brutos

SILVER: Contém dados pré processados e limpos

GOLD: Guarda dados prontos para análise e consumo final

Arquitetura Medalhão

Arquitetura Medallion organiza o pipeline de dados em camadas progressivas de qualidade e valor analítico. Esse modelo melhora governança, rastreabilidade, qualidade dos dados e desempenho analítico, além de facilitar manutenção e evolução do pipeline.

01 Camada Bronze

Nesta camada foi realizada a ingestão inicial dos dados da PNAD COVID a partir de arquivos compactados.
Os arquivos CSV foram extraídos, tratados e convertidos para formato Parquet, sendo armazenados no Amazon S3 utilizando particionamento por ano e mês.
O objetivo dessa camada é preservar os dados na forma mais próxima da origem, garantindo rastreabilidade e reprocessamento caso necessário.

02 Camada Silver

Nesta etapa os dados foram processados utilizando AWS Glue com Spark, realizando:

- Seleção das variáveis relevantes;
- Padronização de nomes de colunas;
- Ajuste de tipagem dos dados;
- Tratamento de valores nulos;
- Organização da base em estrutura analítica.

Os dados tratados foram novamente gravados em Parquet no S3, mantendo o particionamento temporal para otimizar consultas.

03 Camada Gold

Na camada Gold foi realizada a integração entre a base de fatos e o dicionário de dados, traduzindo códigos numéricos em descrições compreensíveis.

Isso resultou em uma tabela analítica enriquecida e preparada para consumo por ferramentas de BI.

Amazon Simple Storage Service (S3)

O Amazon S3 foi utilizado como Data Lake para armazenamento dos dados em formato Parquet, otimizado para leitura analítica e processamento distribuído.
A estrutura de pastas foi organizada com particionamento por ano e mês, permitindo que ferramentas como Apache Spark e Athena leiam apenas os dados necessários em cada consulta, melhorando desempenho e reduzindo custos de processamento.

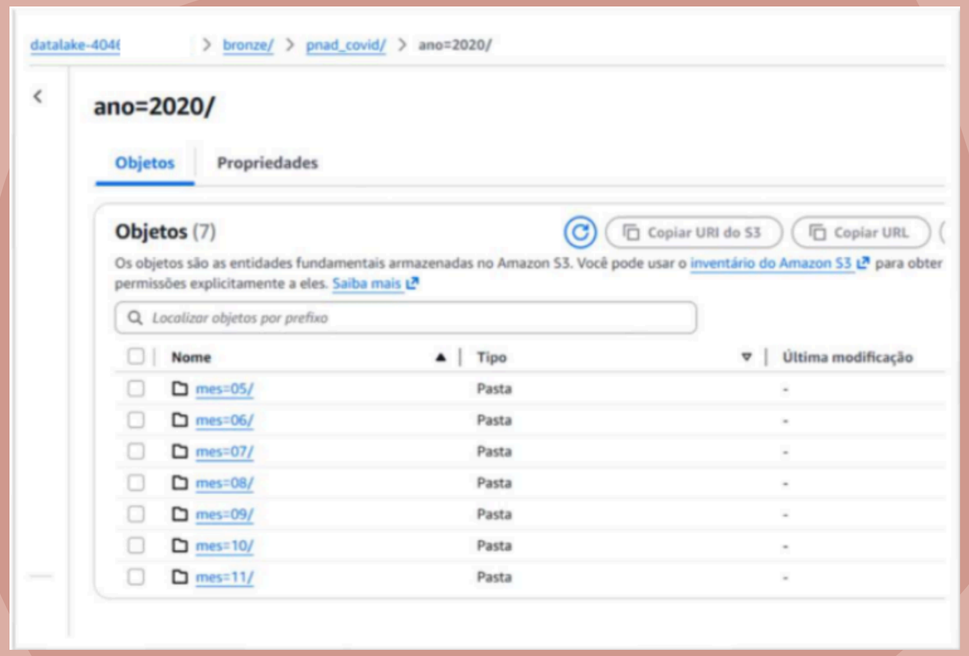

Amazon AWS Glue

O AWS Glue foi utilizado para realizar o processamento e transformação dos dados entre as camadas da arquitetura Medallion, utilizando notebooks com Apache Spark para limpeza, padronização e enriquecimento das bases.
Os Glue Crawlers foram responsáveis por identificar automaticamente a estrutura dos arquivos armazenados no S3 e registrar os metadados no AWS Glue Data Catalog, permitindo que ferramentas como Amazon Athena e Power BI consultem os dados de forma estruturada.

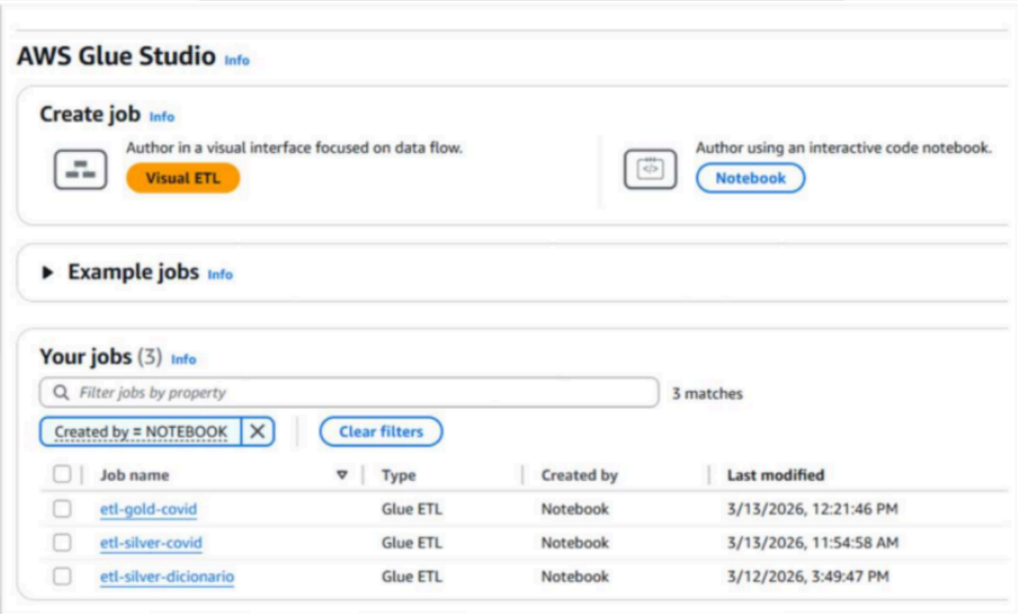

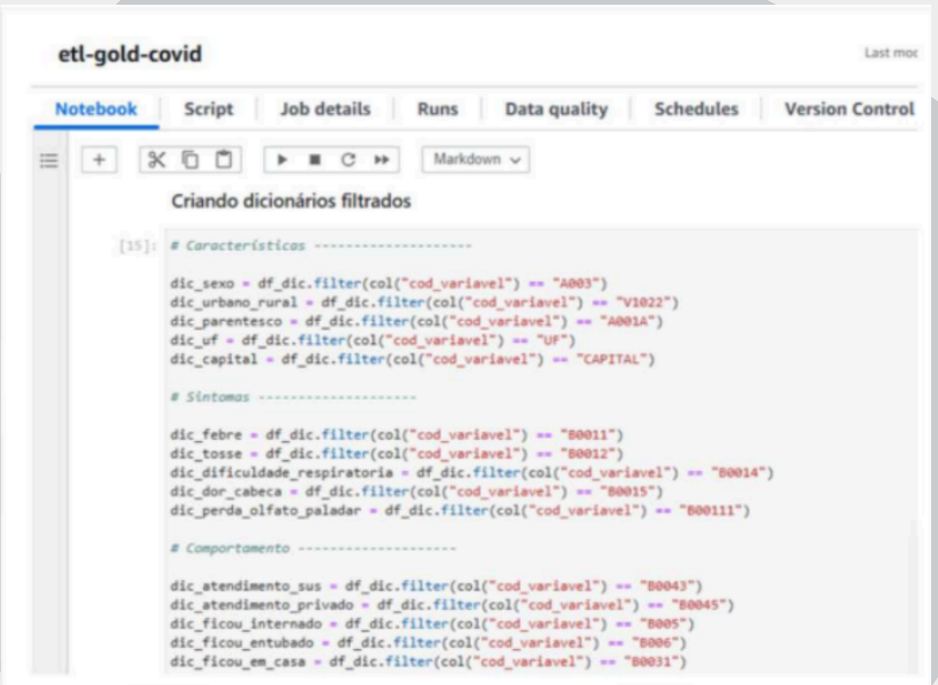

AMAZON ATHENA

O Amazon Athena foi utilizado como mecanismo de consulta para acessar os dados armazenados no Data Lake no Amazon S3. A partir dos metadados registrados no AWS Glue Data Catalog, foi possível consultar os arquivos em formato Parquet utilizando SQL, sem necessidade de provisionar servidores. Essa abordagem permite realizar análises de forma rápida, escalável e com baixo custo, além de facilitar a integração com ferramentas de BI como o Power BI para construção de dashboards analíticos.

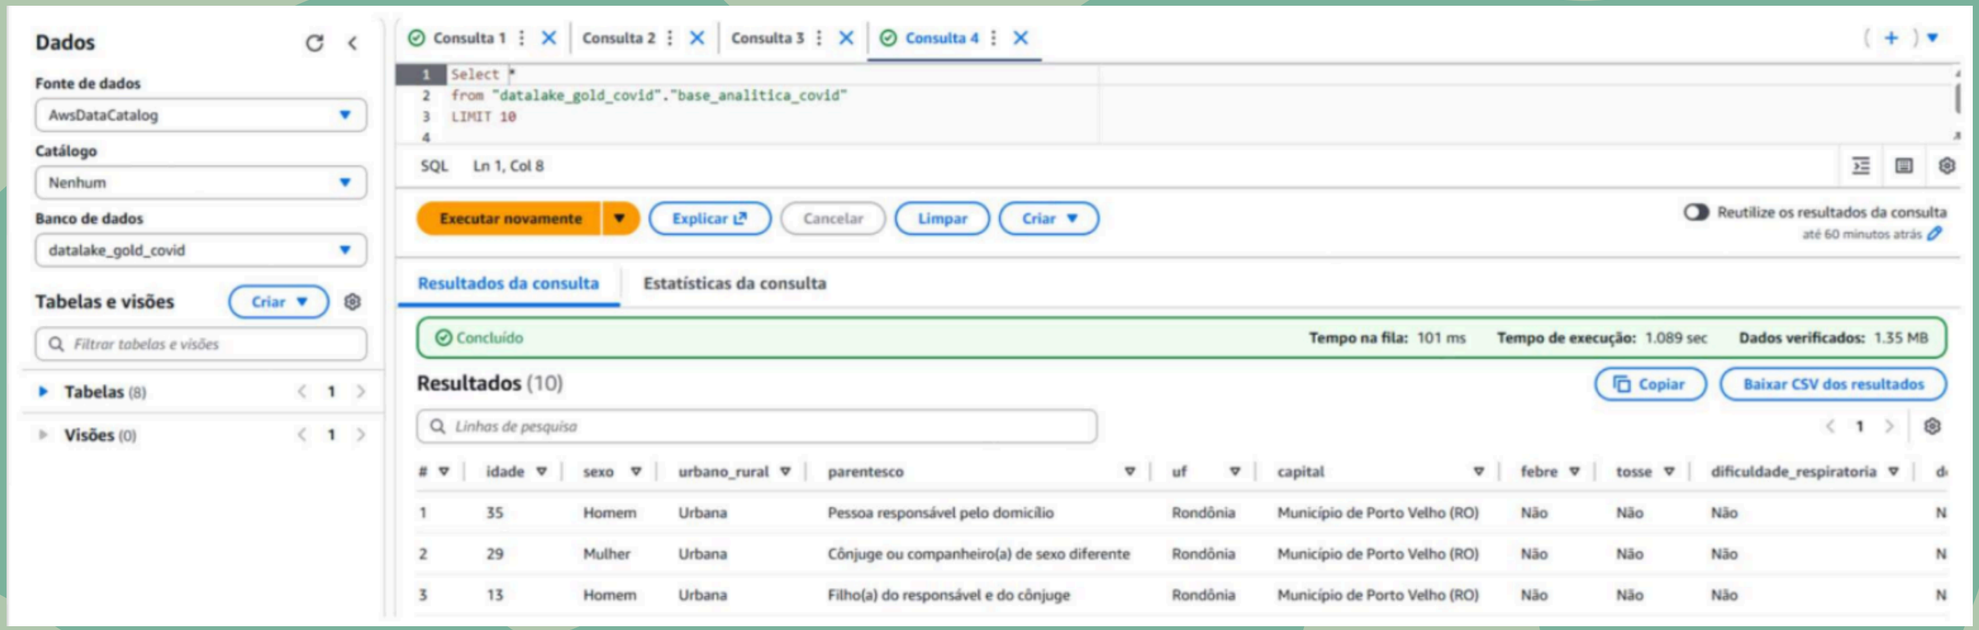

ANÁLISES NO DASHBOARD

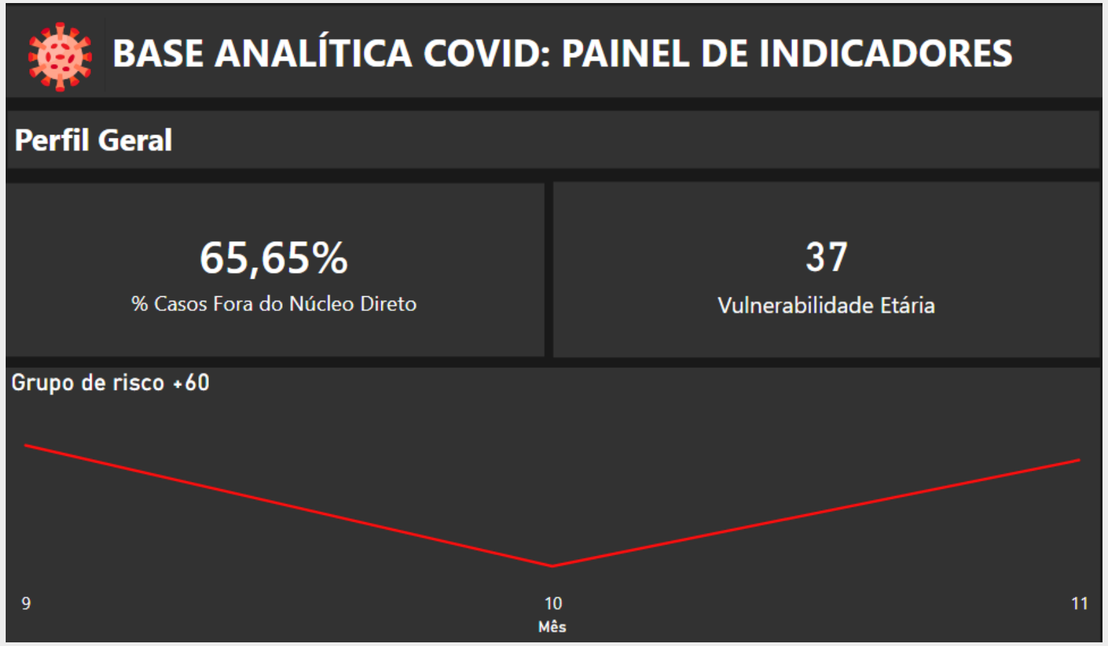

- 65,65% DOS CASOS OCORRERAM FORA DO NÚCLEO DIRETO, COM DISSEMINAÇÃO COMUNITÁRIA RELEVANTE
- IDOSOS +60 CONCENTRAM O MAIOR VOLUME DE CASOS
- FAIXAS DE 30 A 49 ANOS TAMBÉM APRESENTAM ALTA INCIDÊNCIA, FAZENDO PARTE DO GRUPO ECONOMICAMENTE ATIVO

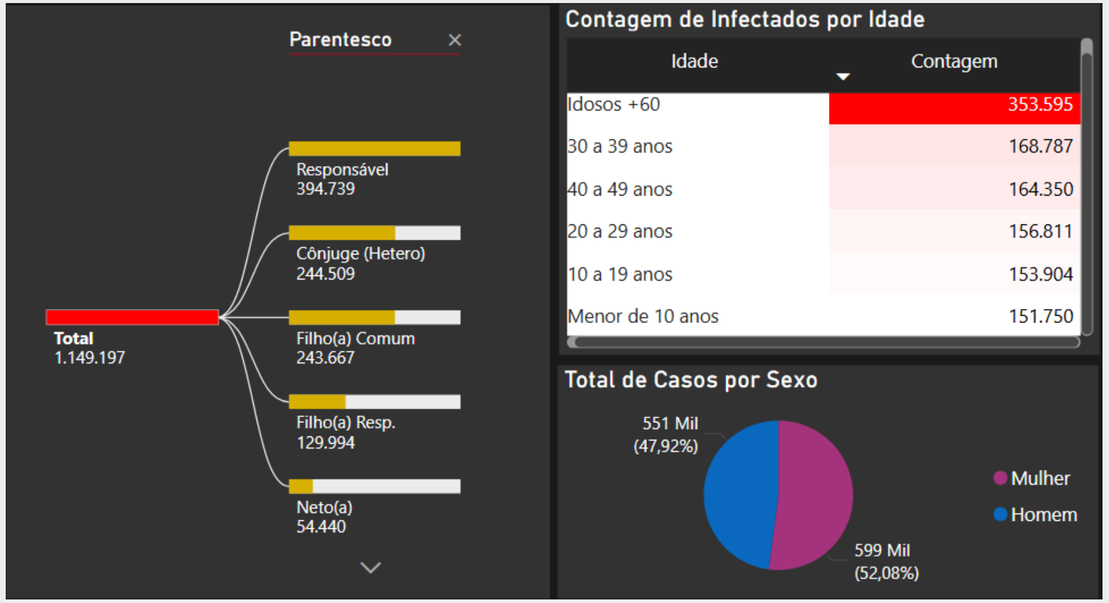

- MAIOR CONCENTRAÇÃO DE CASOS COM RESPONSÁVEIS FAMILIARES, PRINCIPALMENTE EM FILHOS E CÔNJUGES
- INDÍCIO DE TRANSMISSÃO DENTRO DAS CASAS BEM RELEVANTE

POWER BI

ANÁLISES NO DASHBOARD

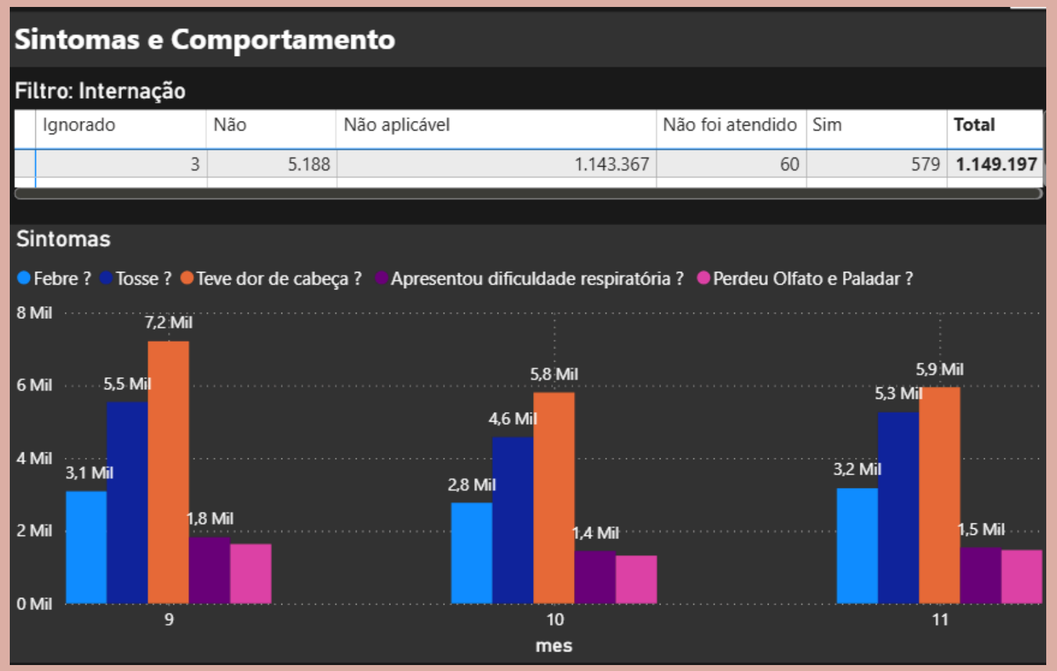

	Ignorado	Não	Não aplicável	Não foi atendido	Sim	Total
	3	5.188	1.143.367	60	579	**1.149.197**

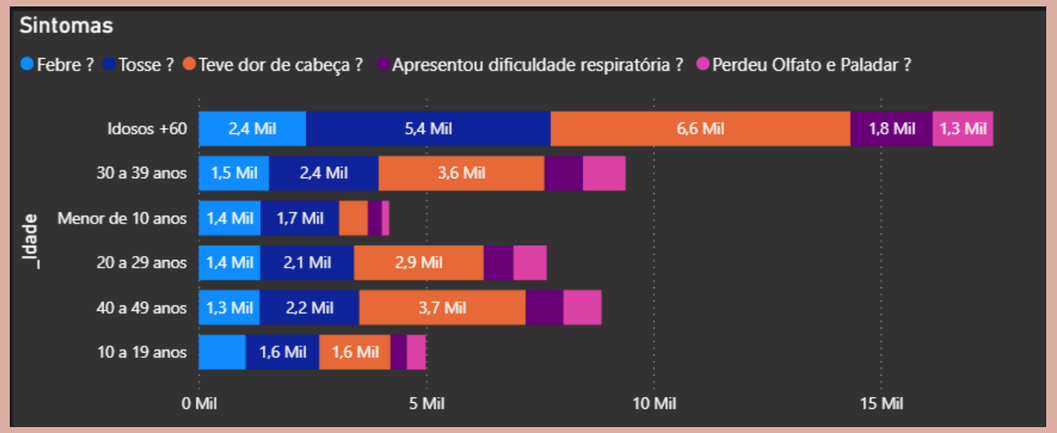

- BAIXO VOLUME DE INTERNAÇÕES EM RELAÇÃO AO TOTAL, A MAIORIA DOS CASOS FORAM CONSIDERADOS LEVES/MODERADOS
- DOR DE CABEÇA (MAIS PREVALENTE), TOSSE E FEBRE SÃO OS SINTOMAS MAIS FREQUENTES

POWER BI

ANÁLISES NO DASHBOARD

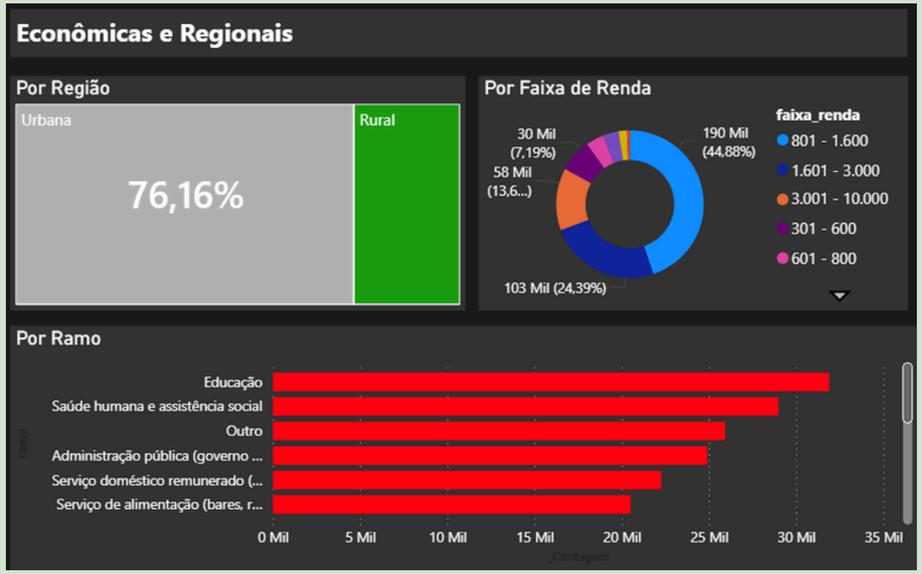

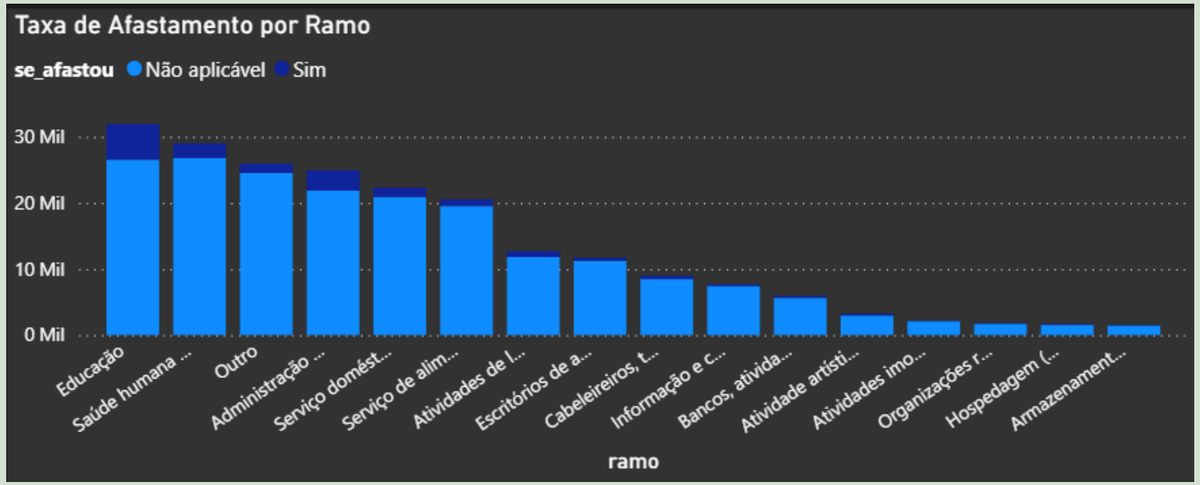

- FORTE CONCENTRAÇÃO EM ESTADOS MAIS POPULOSOS, COM DISSEMINAÇÃO MAJORITARIAMENTE URBANA
- MAIOR CONCENTRAÇÃO EM FAIXAS DE RENDA DE R$ 801 A R$ 1.600 E DE R$ 1.601 A R$ 3.000 (TOTALIZANDO 68%) E MOSTRANDO FORTE RELAÇÃO COM CLASSES DE MÉDIA-BAIXA RENDA
- POPULAÇÕES DE MENOR RENDA SÃO MAIS EXPOSTAS E IMPACTADAS
- ALTA EXPOSIÇÃO EM SERVIÇOS DE CONTATO DIRETO, COMO EDUCAÇÃO, SAÚDE E ASSISTÊNCIA SOCIAL, OUTROS E ADMINISTRAÇÃO PÚBLICA E CONSEQUENTEMENTE IMPACTO DIRETO NA FORÇA DE TRABALHO

Obrigado!